

MemoDoc — 答辩讲解文档

带长期记忆与跨语言检索的文档问答 Agent 演示方式：本文档翻页讲解 + 关键节点切到运行中的 `app.py` (<http://127.0.0.1:7860>) 总时长 ≤ 6 分钟（含提问） | 讲解+演示 $\approx 4:00$ | 提问 $\approx 2:00$ 讲解节奏：① 定位 30s → ② 架构 55s → ③ 现场演示 90s → ④ 评测 55s → ⑤ 记忆 15s → 收尾


1 项目定位（30 秒）

MemoDoc：一个带长期记忆的文档问答 Agent。

- 🔑 **RAG 检索链路完全手搓实现**——没有套 LangChain
- 🔑 **跨语言**：中文提问 × 英文论文，也能答
- 🔑 **跨会话记忆**：这次说"我是大一新生"，下次新会话它还记得

一句话：不是"接了个 RAG 库"，而是把 RAG 的每一层自己搭出来，再叠加跨语言与记忆。


2 系统架构：三条数据流（55 秒，重点）



一句话讲法：索引流负责"把知识存进去"，问答流负责"带着知识和记忆回答"，记忆流负责"跨会话记住你"。

3 检索链路详解（重点中的重点）

3.1 一条完整的检索链路



3.2 四层升级，每层都有"为什么"和"效果"

层	做什么	为什么	实测效果
① 向量+BM25 融合	向量召回与稀疏召回加权合并	向量擅长语义改写 ("会费"≈"社费")、BM25 擅长精确命中，单用都会漏	论文 recall +9pp
② 跨语言双语检索	中文问题翻译成英文，中英各查一遍再合并	中文 embedding 对英文文档弱，"中文问英文论文"答不上	纯中文主题查询可命中英文论文
③ 文档路由	问题含论文标题 → 限定到该文档查	8 篇论文混库时"xx论文"会串库	简称/缩写正确定位，不再串
④ 交叉编码器重排	粗召回 30 → 逐对打分 → 精排 6	双塔粗排不够准，交叉编码器把"问题+片段"拼一起打分	论文 recall 82%→100%

3.3 自研点清单 ("手搓"证据)

自研模块	说明
BM25 稀疏检索	手写倒排索引 + k1/b 打分 (jieba 分词、中英文自适应)
加权融合	各自 min-max 归一化后加权合并
跨语言翻译检索	LLM 查询翻译 + 双语候选合并
文档路由	标题三级匹配 + 唯一词路由 (解决 MEM1/MemMachine 单词标题)
向量库	numpy 余弦 + JSON 持久化 (接口对齐 ChromaDB, 可替换)
记忆系统	抽取→向量去重→冲突更新→增强检索
引用核查	生成后 LLM 逐条验证 [n] 支持性

4 现场演示 (90 秒, 切到 app)

下面打开运行中的系统演示。(切换动作放这里)

#	提问	演示亮点
1	Agent-OS论文的主要贡献是什么？	中文问英文论文 → 检索命中该论文 → 引用高亮 ✓
2	今天北京天气怎么样？	抗幻觉：答"文档中没有相关信息"
3	我是大一新生，刚加入极客社。	右侧记忆面板出现"身份/年级"
4	我还需要交会费吗？	记忆个性化：结合"大一新生"+30元/学期+引用

时间不够 → 只做 1、2、4；再不够 → 1、2 + 记忆截图。兜底：API 故障就关网演示检索/引用/记忆面板，或切本页下方结果表。

5 评测效果 (重点展示)

5.1 指标定义

指标	含义
recall@k 三档	答案片段进没进 top-k：纯向量 / 混合 / 混合+重排
引用准确率	引用的 [n] 是否对应含答案的片段（严格口径）
关键词覆盖	回答是否含标注的必备词（答案质量）
引用核查通过率	LLM 判定每个 [n] 是否真的被片段支持（抗幻觉）

5.2 三场景结果

场景	用例	recall 纯向量/混合/+重排	关键词覆盖	引用核查
demo（受控中文）	7 问	100% / 100% / 100%	100%	100%
论文（跨语言）	11 问	73% → 82% → 100%	100%	76%*
软件工程（中文课程）	19 问	79% / 79% / 84%+	84%	95%

* 裁判模型波动区间 64–95%（deepseek-v4-flash），非系统问题 + 4 级标题合并修复后复测预期 90%+

5.3 改进前后对比（借鉴 Kotaemon 的量化收益）

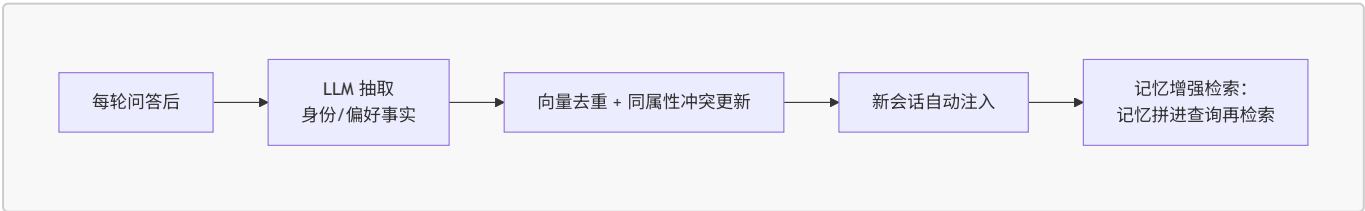
快照	论文 recall（三档）
修复前（500 字分块 + 裸 PyMuPDF）	55% / 64% / 73%
修复后（900/180 分块 + 连字符修复 + 解析增强）	73% / 82% / 100%

5.4 RAGAS 交叉验证（论文场景）

faithfulness 忠实度	answer_relevancy 相关性	context_precision 精度	context_recall 召回
0.96	0.94	0.94	0.44*

* 中文参考答案 ↔ 英文片段语义匹配偏弱（跨语言评估口径）

6 长期记忆（15 秒，简说）



一句话：每轮把用户身份/偏好抽成结构化事实，去重更新后跨会话注入，还拿记忆去增强检索——演示 3、4 两步就是它。

7 已知边界（诚实收尾，防追问）

- 1. 列表型问题（“从低到高列举”）在 top-k 下可能漏尾项 → 已用 4 级标题合并缓解

- 2. 引用核查依赖 LLM 裁判 → 标注波动区间，不夸大
- 3. 复杂版面 PDF（双栏/扫描）解析为演进项（可上 Docling）
- 4. 演示级规模（8 篇论文级语料）；向量库接口对齐可换生产级

8 数据可复现

```
python tests\eval.py                                # demo 三档对比
python tests\eval_papers.py --tags 论文             # 论文跨语言
python tests\eval_softeng.py --tags 课程笔记        # 软件工程
python tests\eval_ragas.py                          # RAGAS 四指标
# 原始结果存档: data/eval/raw/
```

附录 A：逐字稿（排练用，~950 字 / 4 分钟）

- ① 开场（25s）：各位老师好。我的作品叫 MemoDoc——带长期记忆的文档问答 Agent。三个定位：RAG 完全手搓、没有套 LangChain；支持中文问英文论文的跨语言检索；有跨会话记忆。按架构、演示、评测、记忆四块介绍，最后留时间提问。
- ② 架构（55s）：先讲重点——架构。三条数据流：索引流把文档解析、分块、本地 bge 向量化，同时建立手写的 BM25 索引；问答流是核心，检索做四层升级——向量和 BM25 加权融合补语义盲区；跨语言检索解决中文问英文；文档路由避免串到别的论文；交叉编码器把粗召回 30 条精排到 6 条。生成强制只依据片段并标 [编号]，引用能和原文一一对应。这里强调：BM25、融合、路由、重排调度都是自己实现的。
- ③ 演示（90s）：下面运行演示。（按 §4 顺序，语言从简）
- ④ 评测（55s）：评测是重点。我建了三套测试集：受控中文 7 题、跨语言英文论文 11 题（8 篇真实论文）、中文课程 19 题；指标是检索三档召回对比 + 引用准确率 + 关键词覆盖 + 引用核查。结果：demo 三档 100%；论文场景纯向量 73%、混合 82%、重排 100%——每层升级都有实测增益；课程 84%。抗幻觉：引用核查通过率最高 95%，问文档外问题明确拒绝。还用 RAGAS 交叉验证，忠实度 0.96。做了前后对比：借鉴 Kotaemon 分块与解析后，论文召回 73%→100%。原始结果可复现。
- ⑤ 记忆（15s）：记忆借鉴 mem0——每轮让大模型抽取用户身份/偏好，向量去重冲突更新，新会话注入并做增强检索。演示里"大一新生还要交会费吗"就是它。
- ⑥ 收尾：我的演示完毕，欢迎老师提问。

附录 B：评委高频问题预案

问题	回答要点
为什么手搓不套 LangChain?	手搓能讲清每一层原理（BM25 公式/融合权重/路由规则），套框架只能讲调参；工作量在检索四层
BM25 和向量为什么融合?	向量管语义（会费≈社费）、BM25 管精确词；单用都漏，融合后论文 recall +9pp

问题	回答要点
重排为什么用交叉编码器？	双塔算向量相似度粗；交叉编码器把"问题+片段"拼一起打分更准，所以只对粗召回 30 条精排
跨语言为什么翻译而非换多语言 embedding？	两者都可行；翻译零新增模型、复用现有 LLM，且已到 100% recall
引用幻觉怎么压？	三层：只依据片段+编号 / 无片段禁引用 / 生成后 LLM 逐条核查
记忆怎么去重更新？	向量最近邻相似度 $\geq$ 阈值判重复；同属性冲突用新事实替换
分块为什么 900/180？	小分块把摘要列表劈开致关键词跨块（实测假阴性）；借鉴 Kotaemon，论文 73 $\rightarrow$ 100%
为什么自研向量库？	本机无 MSVC、ChromaDB 编译不了；numpy+JSON 演示规模够、接口可替换
评测怎么保证可信？	三档可复现、原始存档、RAGAS 交叉验证、裁判波动如实标注